

INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO

Licenciatura en Ciencia de Datos

THE DATA MACHINE

Análisis de reseñas de videojuegos mediante Procesamiento de Lenguaje Natural

Aplicación web desarrollada con CRISP-DM, VADER, TF-IDF y Streamlit

Unidad de aprendizaje	Desarrollo de Aplicaciones para Análisis de Datos
Profesora	Sandra Luz Morales Güitrón
Grupo	4AV1
Integrantes	Hernández López Melanie Navarrete Flores Yariel Sojo Ponce Melina Valeria
Repositorio	https://github.com/MelSurikun/the-data-machine
Aplicación	https://the-data-machine-01.streamlit.app/
Fecha	Junio de 2026

Millones de opiniones históricas. 5,000 reseñas recientes analizadas en detalle.

Resumen

The Data Machine es una aplicación web que integra metadata histórica de Steam con una muestra reciente de reseñas individuales para presentar análisis de sentimiento y temas recurrentes. El dataset limpio contiene 10,348 videojuegos y métricas agregadas que representan 41,407,431 reseñas históricas. La versión académica selecciona 10 videojuegos —que acumulan 8,854,428 reseñas históricas— y procesa 5,000 textos recientes, 500 por título. El pipeline obtiene reseñas, las normaliza, aplica VADER para sentimiento, extrae términos mediante TF-IDF y genera un paquete compacto con hashes SHA-256. La aplicación Streamlit ofrece catálogo, dashboard, métricas de evaluación, matriz de confusión, nube de palabras, filtros y descargas. La evaluación binaria sobre reseñas no neutrales obtuvo 80.4 % de accuracy promedio, 72.6 % de balanced accuracy y 74.1 % de cobertura promedio. Siete de diez juegos alcanzaron al menos 75 % de accuracy, aunque solo cuatro superaron el baseline mayoritario, lo que evidencia la importancia de evaluar modelos con múltiples métricas. La solución fue desplegada en Streamlit Community Cloud con Python 3.12 y validada mediante 33 pruebas automatizadas.

Palabras clave: procesamiento de lenguaje natural, VADER, TF-IDF, Steam, reseñas, Streamlit, CRISP-DM, análisis de sentimiento.

Abstract

The Data Machine is a web application that combines historical Steam metadata with a recent sample of individual reviews to present sentiment analysis and recurring topics. The cleaned dataset contains 10,348 games and aggregated metrics representing 41,407,431 historical reviews. The academic version selects 10 games —representing 8,854,428 historical reviews— and processes 5,000 recent texts, 500 per game. The pipeline retrieves reviews, normalizes them, applies VADER sentiment analysis, extracts terms with TF-IDF, and builds a compact production package with SHA-256 hashes. The Streamlit application provides a catalog, dashboard, evaluation metrics, confusion matrix, word cloud, filters, and downloads. Binary evaluation over non-neutral reviews reached 80.4% mean accuracy, 72.6% mean balanced accuracy, and 74.1% mean coverage. Seven out of ten games reached at least 75% accuracy, but only four exceeded the majority-class baseline, showing the need for multi-metric evaluation. The solution was deployed on Streamlit Community Cloud using Python 3.12 and validated with 33 automated tests.

Keywords: natural language processing, VADER, TF-IDF, Steam, reviews, Streamlit, CRISP-DM, sentiment analysis.

Contenido

1. Introducción
2. Objetivos y alcance
3. Metodología CRISP-DM
4. Datos e ingesta
5. Modelamiento NLP

6. Arquitectura e implementación

7. Resultados y evaluación

8. Despliegue y calidad

9. Limitaciones y trabajo futuro

10. Conclusiones

Referencias

1. Introducción

Steam reúne millones de opiniones que describen experiencias, problemas técnicos, mecánicas, precio y percepción de valor. El volumen hace imposible la lectura manual completa, mientras que métricas agregadas como el porcentaje positivo no explican por qué la comunidad reacciona de cierta manera. The Data Machine aborda este problema mediante una aplicación web que combina contexto histórico y análisis textual reciente.

El proyecto se desarrolló en la unidad de aprendizaje Desarrollo de Aplicaciones para Análisis de Datos de la Licenciatura en Ciencia de Datos de ESCOM-IPN. La solución aplica CRISP-DM para organizar el entendimiento del problema, la preparación, el modelamiento, la evaluación y el despliegue.

Durante la fase de entendimiento de datos se identificó una distinción fundamental: el dataset limpio contiene una fila por videojuego y métricas históricas agregadas, pero no millones de filas de opiniones. Por ello, se incorporó una fuente de reseñas individuales recientes. La comunicación final del alcance distingue entre millones de opiniones históricas representadas y 5,000 textos procesados en detalle.

2. Objetivos y alcance

2.1 Objetivo general

Construir una aplicación web reproducible que permita seleccionar un videojuego, analizar reseñas recientes con técnicas de NLP, comparar los resultados con métricas de Steam y presentar sentimiento, temas y datos descargables en un dashboard interactivo.

2.2 Objetivos específicos

- Validar y utilizar dataset_limpio.csv como fuente maestra de metadata.
- Definir un catálogo estable de 10 videojuegos mediante appid.
- Obtener y deduplicar 500 reseñas recientes por videojuego.
- Clasificar sentimiento con VADER y evaluarlo contra voted_up.
- Extraer 15 términos TF-IDF y 15 tags por videojuego.
- Construir navegación Login–Homepage–Análisis con manejo de sesión.
- Generar un paquete compacto de producción con integridad verificable.
- Desplegar la aplicación en una URL pública y automatizar pruebas.

2.3 Alcance

Componente	Alcance implementado
Catálogo	10 videojuegos populares
Corpus NLP	5,000 reseñas recientes en inglés
Contexto	8,854,428 reseñas históricas de los juegos seleccionados
Sentimiento	VADER: positivo, neutral y negativo
Temas	15 términos TF-IDF y 15 tags por juego
Interfaz	Login, catálogo, cuatro pestañas, filtros y descargas




Figura 1. Pantalla de acceso de The Data Machine.

3. Metodología CRISP-DM

Fase	Aplicación	Producto
1. Entendimiento del negocio	Definición de usuarios, preguntas, criterios de éxito y restricciones.	Objetivos y alcance
2. Entendimiento de los datos	Auditoría del dataset, 48 columnas, catálogo y diferencia entre métricas agregadas y texto individual.	Verificación de base
3. Preparación	Limpieza, normalización, scraping, deduplicación, hashes y filtrado por appid.	Corpus de 5,000 reseñas
4. Modelamiento	VADER, TF-IDF, tags y nube de palabras.	Resultados NLP
5. Evaluación	Accuracy, balanced accuracy, precision, recall, F1, cobertura, matriz y baseline.	Métricas por juego
6. Despliegue	Paquete compacto, pruebas, arranque headless y Community Cloud.	URL pública

CRISP-DM se aplicó de forma iterativa. El hallazgo sobre la columna reviews obligó a regresar desde modelamiento hacia entendimiento y preparación de datos. El scraping dejó de ser un complemento opcional y se convirtió en la fuente principal de textos individuales.

4. Datos e ingesta

4.1 Dataset base

dataset_limpio.csv pesa aproximadamente 68.6 MiB, contiene 10,348 filas y 48 columnas. Su SHA-256 es b79786bad6eed3ac23b2b51f0104d5fc57ed7cf34f4e1f0ef5e3f6c2e7e7ed5. Las columnas usadas incluyen appid, name, header_image, genres, tags, pct_pos_total, num_reviews_total, positive, negative, metacritic_score, price, estimated_owners y average_playtime_forever.

La suma de num_reviews_total es 41,407,431. Este valor representa contexto histórico agregado, no textos procesados por VADER.

4.2 Catálogo

config/catalogo.json fija 10 appids y su orden. El identificador appid evita ambigüedades de nombre y permite cambiar el catálogo sin acoplar la interfaz a títulos específicos.

4.3 Scraping y normalización

src/scrapper.py obtiene reseñas recientes mediante solicitudes paginadas. El módulo normaliza texto, recomendación, fecha, tiempo de juego y votos; elimina HTML, reintenta fallos, respeta pausas y combina resultados sin eliminar reseñas previas. review_hash actúa como llave de deduplicación.

4.4 Paquete de producción

data/production contiene cinco archivos de datos y manifest.json. El paquete ocupa aproximadamente 2.47 MiB y permite desplegar la aplicación sin cargar el dataset completo ni ejecutar scraping durante la sesión.

Archivo	Filas	Función
catalogo_10_juegos.csv	10	Metadata
reviews_analizadas.csv	5,000	Corpus y sentimiento
metricas_sentimiento.json	10	Evaluación por juego
temas_tfidf.csv	150	Términos relevantes
tags_steam.csv	150	Tags comunitarios
manifest.json	—	Integridad y trazabilidad

5. Modelamiento NLP

5.1 Sentimiento con VADER

VADER calcula un compound score en [-1, 1]. Se aplican los umbrales estándar: positivo si compound ≥ 0.05 , negativo si compound ≤ -0.05 y neutral en el intervalo restante. La clasificación se almacena por reseña y alimenta las distribuciones del dashboard.

5.2 Evaluación

Steam ofrece `voted_up` como referencia binaria. Debido a que no existe una etiqueta neutral, las predicciones neutrales se excluyen de la matriz binaria y se reporta cobertura no neutral. Se calculan accuracy, balanced accuracy, precision positiva, recall positivo, F1 y baseline de la clase mayoritaria.

5.3 TF-IDF y tags

TfidfVectorizer extrae unigramas y bigramas relevantes para cada juego. Se conservan 15 términos y se presentan por separado de los tags de Steam. La separación evita confundir vocabulario calculado sobre la muestra reciente con etiquetas globales asignadas por la comunidad.

5.4 Nube de palabras

WordCloud visualiza frecuencia léxica y facilita exploración rápida. Su interpretación es descriptiva y debe complementarse con TF-IDF, reseñas y métricas.



Figura 2. Nube de palabras generada para Dota 2.

6. Arquitectura e implementación

La solución separa capas de datos, lógica y presentación. La aplicación no recalcula el corpus durante cada interacción. Los resultados precalculados se cargan mediante `src/dashboard.py` y caché de Streamlit.

Módulo	Archivo	Responsabilidad
Entrada	app.py	Enrutamiento inicial
Sesión	src/navigation.py	Autenticación demostrativa y selección por appid
Menú	src/menu_usuario.py	Navegación y logout

Catálogo	pages/homepage.py	Tarjetas y filtros
Dashboard	pages/analisis.py	Métricas, gráficas, temas y descargas
Backend visual	src/dashboard.py	Carga y transformaciones
NLP	src/nlp.py	VADER, evaluación y TF-IDF
Ingesta	src/scrapper.py	Reseñas recientes
Producción	src/production.py	Paquete y manifiesto




Figura 3. Homepage con sesión activa y navegación lateral.




Figura 4. Catálogo de 10 videojuegos y botones de análisis.

7. Resultados y evaluación

La evaluación global obtuvo 80.4 % de accuracy promedio, 72.6 % de balanced accuracy y 74.1 % de cobertura no neutral. Siete juegos alcanzaron 75 % de accuracy; cuatro superaron el baseline mayoritario.

Juego	Accuracy	Balanced	Cobertura	Baseline	Diagnóstico
Dota 2	78.2 %	73.0 %	56.8 %	71.8 %	Cumple 75 %; supera baseline
War Thunder	69.4 %	70.4 %	77.0 %	56.9 %	Bajo 75 %; supera baseline
Rust	70.8 %	71.8 %	76.6 %	74.9 %	Bajo 75 %; no supera baseline
The Witcher 3: Wild Hunt	93.4 %	80.4 %	72.8 %	97.5 %	Cumple 75 %; no supera baseline
Hollow Knight	83.2 %	66.9 %	74.8 %	97.9 %	Cumple 75 %; no supera baseline
Stardew Valley	93.7 %	75.7 %	82.0 %	98.3 %	Cumple 75 %; no supera baseline
Phasmophobia	70.8 %	66.9 %	81.4 %	67.3 %	Bajo 75 %; supera baseline
Among Us	86.7 %	82.2 %	70.6 %	92.6 %	Cumple 75 %; no supera baseline
Apex Legends	81.7 %	79.3 %	74.4 %	69.1 %	Cumple 75 %; supera baseline
ELDEN RING	76.8 %	59.1 %	74.2 %	93.0 %	Cumple 75 %; no supera baseline




Figura 5. Accuracy de VADER frente al baseline de la clase mayoritaria.

La gráfica muestra que una accuracy alta no garantiza superar un clasificador trivial. En juegos con aprobación extremadamente alta, el baseline se aproxima a 100 %. Por ello, The Data Machine muestra balanced accuracy y baseline además de accuracy.

7.1 Caso Dota 2

Dota 2 obtuvo 78.2 % de accuracy, 73.0 % de balanced accuracy, 56.8 % de cobertura y un baseline de 71.8 %. Cumple la meta y supera el baseline. La muestra reciente tiene 71.4 % de recomendaciones positivas frente a 81.0 % histórico; la diferencia refleja temporalidad y composición de la muestra.




Figura 6. Dashboard de Dota 2 con comparación VADER–Steam.

8. Despliegue y calidad

8.1 Pruebas

El proyecto cuenta con 33 pruebas automatizadas. Cubren scraper, NLP, dashboard, sesión, menú, producción y despliegue. También existen validadores de integración y una prueba headless que inicia Streamlit, consulta el endpoint de salud y termina el proceso.

Conjunto	Cobertura
test_scraper	normalización, HTML, combinación y fallback
test_nlp	VADER, métricas, TF-IDF y tags
test_dashboard	carga, filtros, distribución y matriz
test_navigation	sesión y appid
test_menu_usuario	usuario, juego y logout
test_production	rutas y SHA-256
test_deployment	UTF-8, versiones, config y datos

8.2 Entorno de producción

requirements.txt utiliza UTF-8 sin BOM y versiones fijas. El despliegue se validó con Python 3.12 y Streamlit 1.58.0. La aplicación está disponible en <https://the-data-machine-01.streamlit.app/>.




Figura 7. Construcción e instalación de dependencias en Streamlit Community Cloud.

La URL pública abre directamente el login de The Data Machine, incluso en navegación de incógnito. La plataforma utiliza el paquete compacto incluido en GitHub y no requiere el dataset local.

9. Limitaciones y trabajo futuro

9.1 Limitaciones

- La muestra reciente no es un muestreo aleatorio de toda la historia de Steam.
- VADER puede fallar con sarcasmo, jerga, ambigüedad y reseñas multilingües.
- La evaluación excluye neutrales porque voted_up es binario.
- TF-IDF describe relevancia léxica, no temas semánticos latentes.
- El login es demostrativo y no gestiona credenciales persistentes.
- El despliegue precalcula resultados y no realiza scraping bajo demanda.

9.2 Trabajo futuro

- Parametrizar el catálogo y número de reseñas.
- Incorporar ingesta incremental por fecha.
- Usar Parquet, DuckDB o PostgreSQL para mayor escala.
- Comparar VADER con modelos supervisados y Transformers.
- Agregar detección de idioma y soporte en español.
- Implementar autenticación real y roles.
- Automatizar CI/CD y análisis de cambios temporales.

10. Conclusiones

The Data Machine cumple el alcance académico y demuestra un pipeline completo de ciencia de datos: adquisición, validación, procesamiento, evaluación, visualización, pruebas y despliegue. La solución distingue de forma explícita entre contexto histórico agregado y corpus textual reciente, evitando afirmar que el NLP procesa millones de textos cuando analiza 5,000.

La evaluación muestra que VADER alcanza una accuracy promedio superior a 80 %, pero también evidencia que la clase mayoritaria puede ser un baseline exigente. La incorporación de balanced accuracy, cobertura y matriz de confusión mejora la calidad de la interpretación.

La arquitectura por appid, los archivos precalculados y el manifiesto permiten reproducir la versión 1.0 y constituyen una base para una versión futura más dinámica. El resultado final es una aplicación pública, navegable y verificable que integra conceptos de DAAD, NLP, web scraping, visualización y despliegue.

Referencias

- [1] Chapman, P. et al. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS Inc.
- [2] Hutto, C. J., & Gilbert, E. (2014). VADER: A Parsimonious Rule-based Model for Sentiment Analysis of Social Media Text. Proceedings of ICWSM, 8(1), 216-225.
- [3] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- [4] McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proceedings of SciPy.
- [5] Streamlit. Documentation and Community Cloud. <https://docs.streamlit.io/>

[6] NLTK Project. Natural Language Toolkit. <https://www.nltk.org/>

[7] Scikit-learn. TfidfVectorizer.

https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html

[8] Beautiful Soup Documentation. <https://www.crummy.com/software/BeautifulSoup/bs4/doc/>

[9] Valve Corporation. Steam Store and review endpoints. <https://store.steampowered.com/>

[10] GitHub repository: <https://github.com/MelSurikun/the-data-machine>

Anexo A. Evidencias y rutas de ejecución

```
python -m unittest tests/test_scraper.py tests/test_nlp.py tests/test_dashboard.py tests/test_navigation.py  
tests/test_menu_usuario.py tests/test_production.py tests/test_deployment.py -v
```

```
python scripts/validar_bloque5c.py
```

```
python scripts/prueba_arranque_streamlit.py
```

```
python -m streamlit run app.py
```

URL de producción: <https://the-data-machine-01.streamlit.app/>

Repositorio: <https://github.com/MelSurikun/the-data-machine>